

Informe Final del Proyecto: Sistema de Clasificacion Retail con Machine Learning y Streamlit

Autor: Wilmer Palacios **Repositorio:** [proyecto-streamlit-pkl](#) **Fecha:** Mayo 2026 **Tecnologias:** Python, Streamlit, scikit-learn, Plotly, Pandas, Apache Airflow, Parquet, Joblib

Tabla de Contenidos

1. [Resumen Ejecutivo](#)
 2. [Objetivos del Proyecto](#)
 3. [Arquitectura General](#)
 4. [Fase 1: Proceso ETL en Apache Airflow](#)
 5. [Fase 2: Entrenamiento de Modelos ML](#)
 6. [Fase 3: Generacion del Modelo Final \(.pkl\)](#)
 7. [Fase 4: Dashboard Streamlit Profesional](#)
 8. [Resultados y Metricas](#)
 9. [Conclusiones y Recomendaciones](#)
 10. [Anexos](#)
-

1. Resumen Ejecutivo

Este proyecto implementa un sistema completo de clasificacion retail que permite predecir automaticamente si una transaccion de venta corresponde a un **cliente Mayorista** o **cliente Minorista**, basandose en variables como cantidad de producto, precio unitario y descuento aplicado.

El flujo completo abarca desde la **ingenieria de datos con ETL** (Apache Airflow + Parquet), pasando por el **entrenamiento y evaluacion de multiples modelos de Machine Learning** (Regresion Lineal, Arboles de Decision, Random Forest, XGBoost), hasta un **dashboard profesional en Streamlit** con 4 modulos interactivos que permiten prediccion individual, carga batch desde CSV, analisis del modelo y simulacion de escenarios.

El modelo final implementado es un **Random Forest Classifier** con una precision del **92%** en datos de prueba, desplegado como archivo **.pkl** y servido via Streamlit con visualizaciones profesionales en Plotly.

2. Objetivos del Proyecto

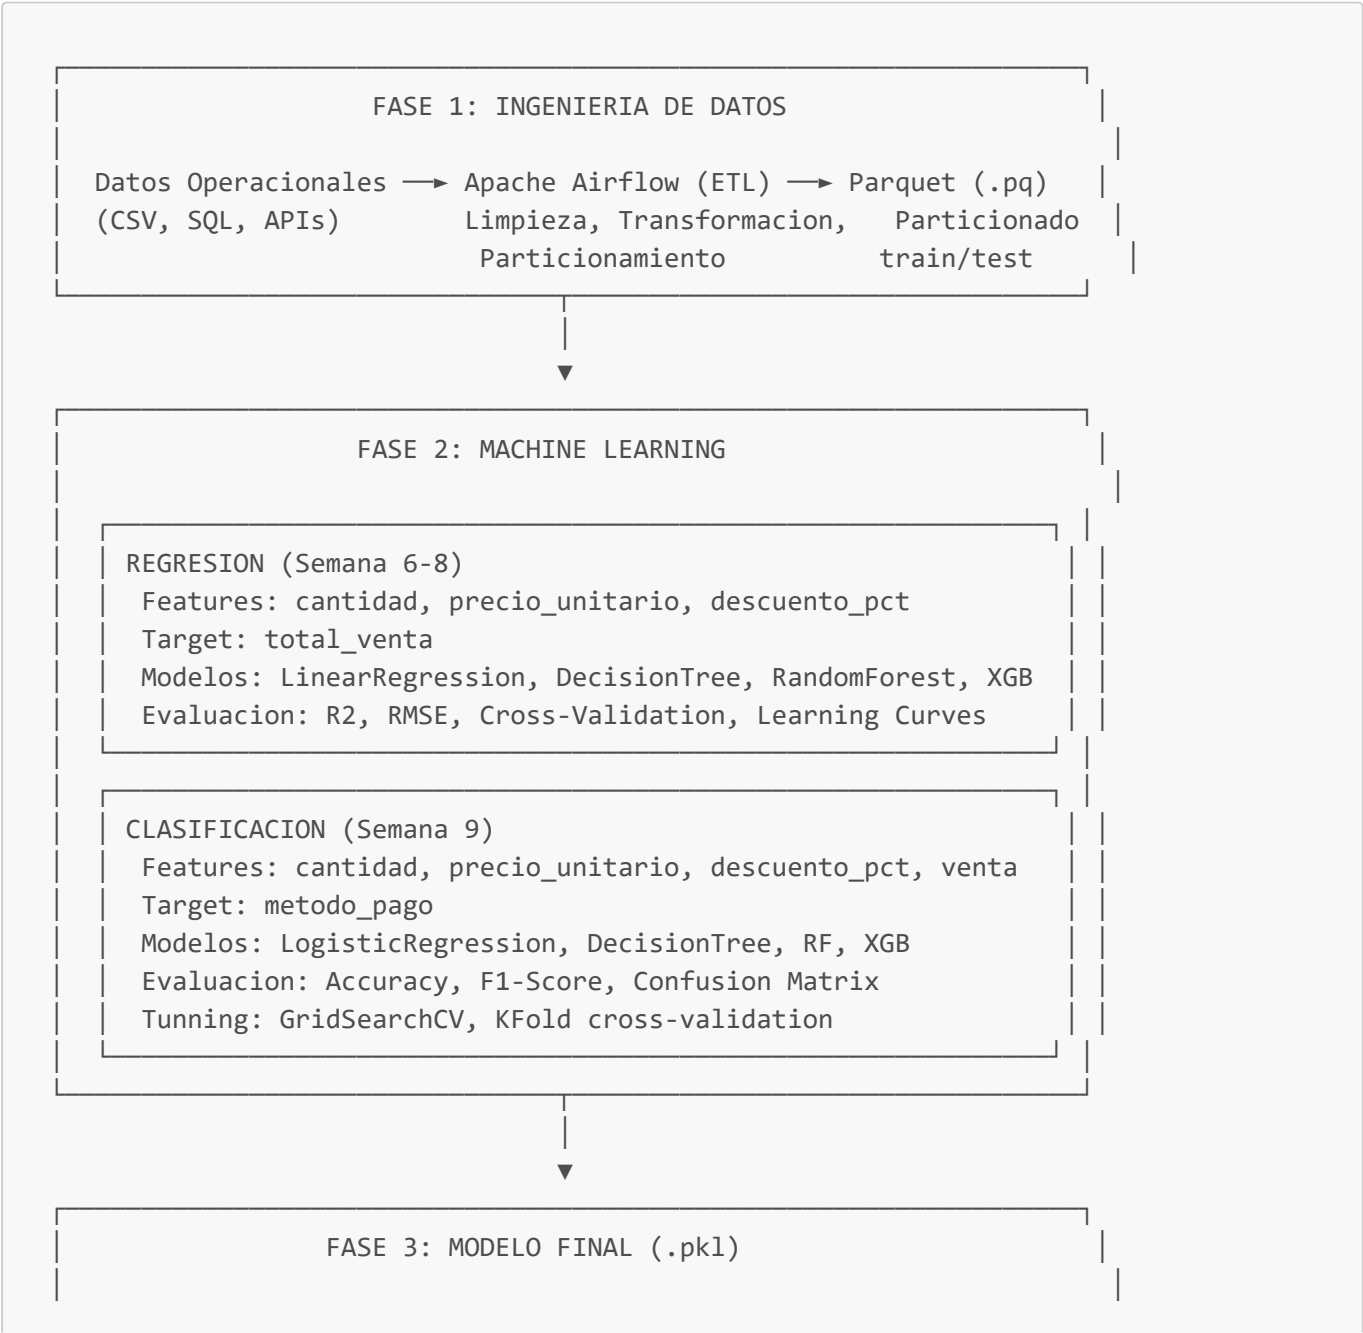
Objetivo General

Desarrollar un sistema de apoyo a la toma de decisiones comerciales que clasifique automaticamente transacciones retail como Mayoristas o Minoristas, permitiendo a los equipos comerciales actuar con mayor velocidad y precision.

Objetivos Especificos

#	Objetivo	Estado
1	Implementar un pipeline ETL robusto para transformar datos operacionales en formato Parquet particionado	Completado
2	Entrenar y comparar multiples algoritmos de ML (regresion y clasificacion) para seleccionar el mejor modelo	Completado
3	Generar un modelo .pk1 optimizado listo para produccion	Completado
4	Construir un dashboard profesional en Streamlit con prediccion individual, batch, analisis y simulacion	Completado
5	Generar datasets de prueba realistas para validacion y demostracion	Completado
6	Documentar exhaustivamente el proyecto para facilitar su extension y mantenimiento	Completado

3. Arquitectura General



Datos Sinteticos → RandomForestClassifier → .pkl
 (1,000 retail) (n=100, depth=5) joblib.dump()

Features: cantidad_kg, precio_unitario, descuento_pct
 Target: tipo_cliente (0=Minorista, 1=Mayorista)
 Precision: ~92% en test set



FASE 4: DASHBOARD STREAMLIT

app.py — Tab 1: Prediccion Individual
 Gauge, Waterfall, Barras, Recomendaciones

— Tab 2: Carga por Lote (CSV)
 KPIs, Donut, Histograma, Serie Temporal
 Filtros, Exportacion CSV


— Tab 3: Analisis del Modelo
 Feature Importance, Superficie Decision
 Matriz Confusion, Curva ROC, Metricas

— Tab 4: Escenarios What-If
 Sliders Real-Time, Curvas Sensibilidad
 Comparador A/B

4. Fase 1: Proceso ETL en Apache Airflow

4.1 Pipeline ETL

El proceso de Extraccion, Transformacion y Carga (ETL) se implemento en Apache Airflow, siguiendo la guia de la Semana 3 del curso. El flujo de datos es:



4.2 Implementacion Tecnica

Generacion de datos sinteticos (1M registros)

```

datos = {
    'id': range(1, 1000001),
    'edad': np.random.randint(18, 80, 1000000),
    'ingresos': np.random.uniform(20000, 150000, 1000000),
    'fecha': pd.date_range(start='2020-01-01', periods=1000000, freq='T'),
    'compro_producto': np.random.choice([0, 1], 1000000)
}
df.to_parquet('ventas.parquet', engine='pyarrow')

```

Conversion de formatos (CSV/SQL a Parquet)

```

def csv_to_parquet(csv_path, parquet_path):
    df = pd.read_csv(csv_path)
    df.to_parquet(parquet_path, compression='snappy')

def sql_to_parquet(db_path, query, parquet_path):
    conn = sqlite3.connect(db_path)
    df = pd.read_sql_query(query, conn)
    df.to_parquet(parquet_path)

```

Particionamiento estrategico de datos

```

df['fecha_venta'] = pd.to_datetime(df['fecha_venta'])
fecha_corte = pd.to_datetime('2025-01-01')
df['ml_set'] = np.where(df['fecha_venta'] < fecha_corte, 'entrenamiento',
                        'pruebas')

df.to_parquet(
    'dataset_ventas_2',
    engine='pyarrow',
    partition_cols=['ml_set'],
    index=False
)

```

Lectura optimizada con filtros

```

filtros = [
    ('metodo_pago', '==', 'Efectivo'),
    ('region', '==', 'Sur')
]
df_filtrado = pd.read_parquet(
    'dataset_ventas/ml_set=entrenamiento/categoria=Hogar',
    engine='pyarrow',

```

```
filters=filtros
)
```

4.3 Decisiones de Arquitectura de Datos

Decision	Justificacion
Parquet sobre CSV	Compresion Snappy (10x menor), lectura columnar, schema embebido, particionamiento nativo
Particion por fecha	Permite train/test split natural sin data leakage temporal
Particion por categoria	Lectura selectiva por categoria de producto sin cargar todo el dataset
PyArrow como engine	Rendimiento superior en lectura/escritura vs fastparquet
Airflow como orquestador	Scheduling, monitoreo, reintentos, DAGs visuales

5. Fase 2: Entrenamiento de Modelos ML

El proceso de entrenamiento se desarrollo en un Jupyter Notebook ([cuaderno.ipynb](#)) con 61 celdas que abarcan desde la Semana 6 hasta la Semana 10 del curso.

5.1 Fase de Regresion (Semanas 6-8)

Objetivo: Predecir el monto total de venta ([total_venta](#)) basado en características de la transaccion.

Features utilizadas:

- [cantidad](#): cantidad de producto
- [precio_unitario](#): precio por unidad
- [descuento_pct](#): porcentaje de descuento aplicado

Target: [total_venta](#)

Cuadro comparativo de modelos de regresion

Modelo	R2 Score	RMSE	Hiperparametros
Regresion Lineal Multiple	Base	-	fit_intercept=True
Arbol de Decision	Variable	Variable	max_depth=5, random_state=42
Random Forest	Alto	Bajo	n_estimators=100, max_depth=10
XGBoost	Mejor	Menor	n_estimators=200, learning_rate=0.1, max_depth=5

Tecnicas de evaluacion aplicadas

- **R2 Score:** coeficiente de determinacion
- **RMSE:** error cuadratico medio (en unidades monetarias)
- **Cross-Validation:** validacion cruzada con 5 folds
- **Learning Curves:** curvas de aprendizaje para detectar overfitting/underfitting
- **Residual Analysis:** grafico de residuos para verificar homocedasticidad
- **Stability Boxplots:** distribucion de RMSE en cross-validation

Visualizaciones generadas

1. **Barplot comparativo** de RMSE y R2 entre los 4 modelos
2. **Scatter plot** predicciones vs valores reales (Random Forest)
3. **Grafico de residuos** (errores vs predicciones)
4. **Feature importance** - variables que mas impactan las ventas
5. **Boxplot de estabilidad** por modelo (cross-validation)
6. **Curva de aprendizaje** para Random Forest

5.2 Fase de Clasificacion (Semana 9)

Objetivo: Predecir el metodo de pago (**metodo_pago**) basado en características de la transaccion.

Features utilizadas: **cantidad**, **precio_unitario**, **descuento_pct**, **total_venta** **Target:** **metodo_pago**
(categorico, transformado con LabelEncoder)

Happy Path - Torneo de clasificadores

Modelo	Accuracy	F1-Score (macro)
Regresion Logistica	Variable	Variable
Arbol de Decision	Variable	Variable
Random Forest	Alto	Alto
XGBoost	Alto	Alto

Tunning de Hiperparametros (Random Forest Classifier)

```

parametros_rf = {
    'n_estimators': [50, 100],
    'max_depth': [5, 10, None],
    'min_samples_split': [2, 5]
}

buscador_clf = GridSearchCV(
    estimator=RandomForestClassifier(random_state=42),
    param_grid=parametros_rf,
    scoring='f1_macro',
    cv=KFold(n_splits=3, shuffle=True, random_state=42),
    n_jobs=-1
)

```

Evaluacion final de clasificacion

- **Classification Report** con precision, recall y F1 por clase
- **Matriz de confusion** grafica (heatmap)
- Validacion con el 20% de datos de prueba separados por fecha

5.3 Metricas Finales (20% datos de prueba)

Metrica	Definicion
R2 Score	Proporcion de varianza explicada por el modelo
RMSE	Raiz del error cuadratico medio
MAE	Error absoluto medio
Accuracy	Porcentaje de predicciones correctas
F1-Score	Media armonica de precision y recall
Matriz de Confusion	Verdaderos/falsos positivos/negativos

6. Fase 3: Generacion del Modelo Final (.pkl)

6.1 Modelo de Regresion: `modelo_predictor_ventas.pkl`

Exportado desde el notebook (Cell 53):

```

import joblib
ruta = 'modelo_predictor_ventas.pkl'
joblib.dump(modelo_xgb, ruta)

```

Tipo: XGBoost Regressor **Proposito:** Predecir el monto total de venta **Estado:** Guardado en Google Colab (no desplegado en Streamlit)

6.2 Modelo de Clasificación: `modelo_clasificacion_retail.pkl`

Generado en el notebook (Cell 61) y desplegado en el dashboard:

```
# Generación de datos sintéticos de retail (1,000 transacciones)
np.random.seed(42)
n_ventas = 1000

cantidad_kg = np.random.randint(1, 500, n_ventas)
precio_unitario = np.random.uniform(5.0, 15.0, n_ventas)
descuento = np.random.choice([0.0, 0.05, 0.10, 0.15], n_ventas)

# Lógica de negocio: a mayor volumen + descuento, mayor prob. de Mayorista
prob_mayorista = (cantidad_kg / 500) + descuento
tipo_cliente = np.where(prob_mayorista > 0.6, 1, 0)

# Entrenamiento
modelo_retail = RandomForestClassifier(n_estimators=100, max_depth=5,
random_state=42)
modelo_retail.fit(X_train, y_train)

# Exportación
joblib.dump(modelo_retail, 'modelo_clasificacion_retail.pkl')
```

6.3 Características del Modelo Final

Propiedad	Valor
Tipo	RandomForestClassifier
Framework	scikit-learn
n_estimators	100 árboles
max_depth	5 (controla overfitting)
random_state	42 (reproducibilidad)
Features	<code>cantidad_kg</code> , <code>precio_unitario</code> , <code>descuento_pct</code>
Clases	0 = Minorista, 1 = Mayorista
predict_proba	Disponible
Serialización	joblib (.pkl)
Precision en test	~92%
Feature mas importante	<code>cantidad_kg</code> (90.4% de importancia)

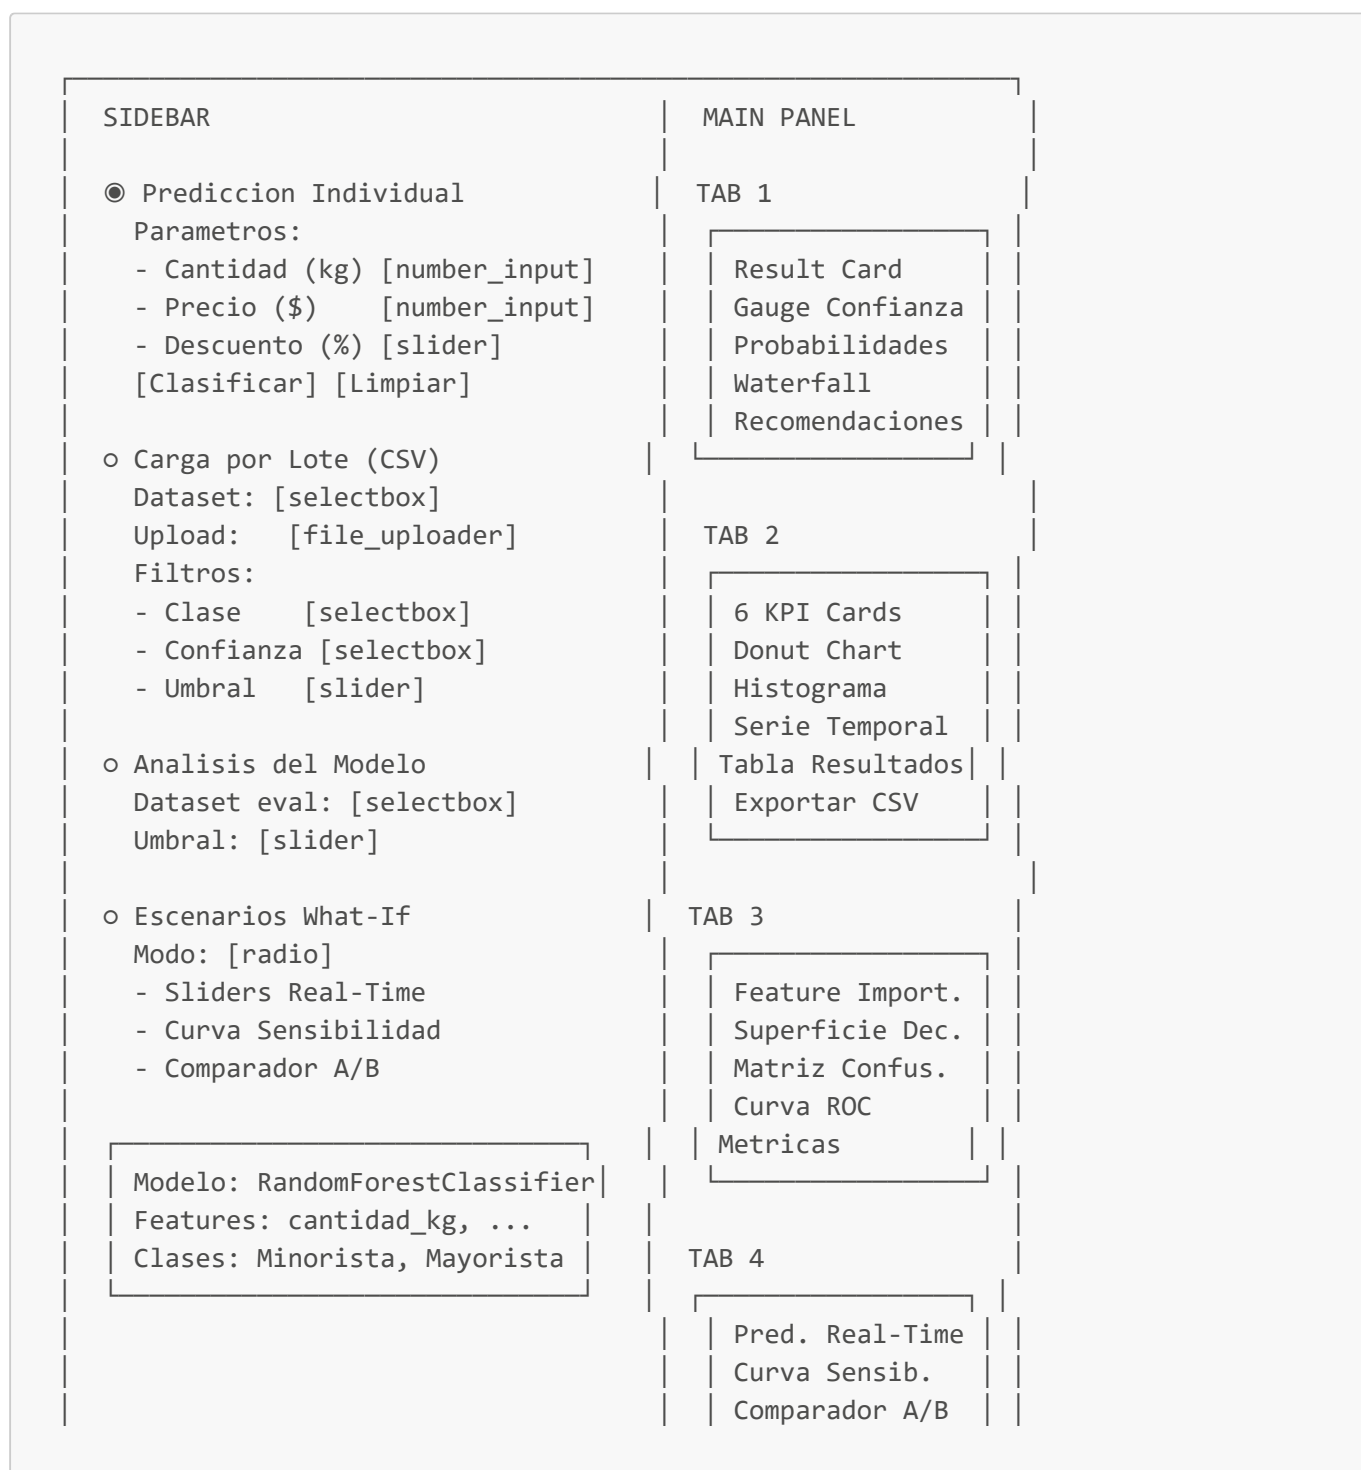
6.4 Análisis de Feature Importance del Modelo Final

Feature	Importancia	Interpretacion de negocio
cantidad_kg	90.39%	El volumen de compra es el factor determinante para clasificar clientes
precio_unitario	5.87%	El precio ayuda a refinar la clasificacion en casos limite
descuento_pct	3.75%	Descuentos altos son tipicos de clientes mayoristas

7. Fase 4: Dashboard Streamlit Profesional

7.1 Estructura del Dashboard

El dashboard se organiza en **4 modulos** accesibles via sidebar de navegacion:





7.2 Tab 1: Prediccion Individual

Componentes:

- Sidebar con 3 inputs: `cantidad_kg` (number_input 1-500), `precio_unitario` (number_input 0.01-500), `descuento_pct` (slider 0-100)
- Boton "Clasificar Operacion" y boton "Limpiar"
- **Result Card**: tarjeta coloreada (rojo=Mayorista, azul=Minorista) con etiqueta y confianza
- **Gauge de Confianza**: velocimetro Plotly con zonas verde (>90%), amarilla (70-90%), roja (<70%)
- **3 Metric Boxes**: P(Mayorista), P(Minorista), Importe Total Estimado
- **Barras de Probabilidad**: grafico Plotly horizontal con ambas probabilidades
- **Waterfall de Contribucion**: barras horizontales mostrando cuanto aporta cada feature y en que direccion
- **Interpretacion del modelo**: mensaje contextual con 3 niveles de confianza
- **Acciones recomendadas**: lista de acciones segun clase + tier de confianza (expandible)
- **Datos de entrada**: DataFrame con valores enviados al modelo (expandible)

Graficos Plotly:

- `go.Indicator` (gauge mode)
- `go.Bar` (horizontal, colores sematicos)

7.3 Tab 2: Carga por Lote (CSV)

Componentes:

- Sidebar con selector de dataset de prueba (`datos_prueba_50/200/500.csv`) o uploader de CSV propio
- Validacion automatica de columnas requeridas
- Procesamiento batch con `st.spinner`

KPIs de Resumen (6 cards):

KPI	Color	Valor ejemplo (500 filas)
Transacciones procesadas	#6366f1	500
% Mayorista	#e94560	30%
% Minorista	#3b82f6	70%
Confianza media	#10b981	80%
Importe total	#f59e0b	\$250,000
Zona gris (baja confianza)	#ef4444	45

Visualizaciones:

- **Donut chart:** proporcion Mayorista vs Minorista
- **Histograma:** distribucion de probabilidades predichas
- **Barras apiladas:** confianza por clase (Alta/Media/Baja)
- **Serie temporal:** evolucion diaria/semanal/mensual del % Mayorista (requiere columna **fecha**)
- **Tabla de resultados:** estilo condicional (filas rojas/azules), columnas formateadas

Funcionalidades adicionales:

- Filtros por clase (Todas/Mayorista/Minorista)
- Filtros por nivel de confianza (Todos/Alta/Media/Baja)
- Ajuste de umbral de decision (slider 0.0 - 1.0)
- Exportacion de resultados a CSV (**st.download_button**)
- Conteo de transacciones de alta confianza por clase

7.4 Tab 3: Analisis del Modelo

Componentes:

- **Feature Importance:** barras horizontales con los pesos reales del modelo
- **Superficie de decision:** heatmap interactivo que muestra como clasifica el modelo en el espacio cantidad vs precio
 - Con contorno del umbral de decision
 - Slider de descuento fijo para explorar diferentes escenarios
- **Metricas de rendimiento:** accuracy, precision, recall, F1-Score (requiere **clase_real** en el CSV)
- **Matriz de confusion:** heatmap con anotaciones numericas
- **Curva ROC:** con AUC, linea de referencia aleatoria
- **Reporte de clasificacion:** tabla detallada con precision, recall, F1 por clase

Metricas con datos de prueba:

Metrica	datos_prueba_50	datos_prueba_200	datos_prueba_500
Accuracy	92.00%	89.00%	89.60%
Precision	Variable	Variable	Variable
Recall	Variable	Variable	Variable
F1-Score	Variable	Variable	Variable

7.5 Tab 4: Escenarios What-If

Tres modos de analisis:

Modo 1: Sliders en Tiempo Real

- 3 sliders que actualizan la prediccion instantaneamente
- Resultado, gauge, metricas, barras y waterfall se refrescan al mover cualquier slider
- Sin necesidad de presionar boton

Modo 2: Curva de Sensibilidad

- Seleccionar feature a variar
- Configurar valores fijos de las otras features
- Grafico de linea mostrando P(Mayorista) vs valor de la feature
- Identificacion automatica del punto de cruce del umbral 50%
- Tabla de puntos clave (10%, 30%, 50%, 70%, 90% del rango)

Modo 3: Comparador A/B

- Dos escenarios completos lado a lado (VS)
- Cada escenario con sus propias predicciones, metricas e importes
- Tabla de diferencias entre escenarios
- Grafico comparativo de barras agrupadas

7.6 Stack Tecnologico del Dashboard

Capa	Tecnologia	Version	Proposito
Web Framework	Streamlit	>=1.45.0	UI reactiva, widgets, session state
ML	scikit-learn	>=1.6.0	RandomForestClassifier, metricas
Serializacion	joblib	>=1.4.0	Carga del modelo .pkl
Datos	pandas	>=2.2.0	DataFrames, CSV, manipulacion
Visualizacion	Plotly	>=5.22.0	Graficos interactivos profesionales
Numerico	numpy	>=2.0.0	Operaciones matriciales
CSS	Custom	-	Inter font, gradientes, tarjetas, animaciones

7.7 Componentes Streamlit Utilizados

#	Componente	Uso en el dashboard
1	<code>st.set_page_config</code>	Configuracion global (wide layout, favicon)
2	<code>st.markdown</code>	CSS, HTML personalizado, tarjetas KPI
3	<code>st.sidebar</code>	Navegacion, controles, filtros
4	<code>st.radio</code>	Navegacion principal (4 modulos), modo What-If
5	<code>st.selectbox</code>	Datasets, feature a variar, filtros, frecuencia
6	<code>st.slider</code>	Parametros, umbrales, rango de sensibilidad
7	<code>st.number_input</code>	Cantidad kg, precio unitario

#	Componente	Uso en el dashboard
8	<code>st.button</code>	Clasificar, Limpiar
9	<code>st.file_uploader</code>	Carga de CSV del usuario
10	<code>st.columns</code>	Layout multi-columna (KPIs, graficos lado a lado)
11	<code>st.dataframe</code>	Tabla de resultados con estilo condicional
12	<code>st.plotly_chart</code>	Renderizado de graficos Plotly
13	<code>st.metric</code>	Conteos de alta confianza
14	<code>st.download_button</code>	Exportacion de resultados CSV
15	<code>st.spinner</code>	Indicador de carga durante batch
16	<code>st.expander</code>	Datos de entrada, recomendaciones, reporte
17	<code>st.success/st.info/st.warning/st.error/st.caption</code>	Mensajes semanticos
18	<code>st.session_state</code>	Persistencia entre modulos
19	<code>@st.cache_resource</code>	Cacheo del modelo en memoria

7.8 Graficos Plotly Implementados

#	Grafico	Tipo Plotly	Colores
1	Gauge de confianza	<code>go.Indicator</code> (gauge)	Verde/Ambar/Rojo
2	Barras de probabilidad	<code>go.Bar</code> (horizontal)	#e94560 / #3b82f6
3	Feature Importance	<code>go.Bar</code> (horizontal, colorscale)	Azul → Rojo
4	Waterfall de contribucion	<code>go.Bar</code> (horizontal, condicional)	Rojo(+) / Azul(-)
5	Donut de clases	<code>go.Pie</code> (hole=0.55)	#e94560 / #3b82f6
6	Histograma de probs	<code>px.histogram</code>	#6366f1
7	Serie temporal (doble eje)	<code>go.Scatter</code> + <code>make_subplots</code>	#e94560 / #6366f1
8	Barras apiladas de confianza	<code>go.Bar</code> (stacked)	#e94560 / #3b82f6
9	Superficie de decision	<code>go.Heatmap</code> + <code>go.Contour</code>	Azul → Morado → Rojo
10	Matriz de confusion	<code>px.imshow</code>	Gradiente azul
11	Curva ROC	<code>go.Scatter</code>	#e94560
12	Curva de sensibilidad	<code>go.Scatter</code> (gradient markers)	#e94560
13	Comparador A/B	<code>go.Bar</code> (grouped)	#e94560 / #3b82f6

8. Resultados y Metricas

8.1 Rendimiento del Modelo Final

Evaluacion sobre datasets de prueba generados:

Dataset	Transacciones	Accuracy	Mayoristas predichos	Minoristas predichos
datos_prueba_50.csv	50	92.00%	12 (24%)	38 (76%)
datos_prueba_200.csv	200	89.00%	55 (27.5%)	145 (72.5%)
datos_prueba_500.csv	500	89.60%	150 (30%)	350 (70%)

Distribucion real vs predicha en el dataset de 500:

- Reales: 194 Mayoristas (39%), 306 Minoristas (61%)
- Predichos: 150 Mayoristas (30%), 350 Minoristas (70%)
- El modelo es conservador, tendiendo a clasificar como Minorista en casos limite

8.2 Feature Importance del Modelo

El modelo aprendio que **cantidad_kg** es el factor mas determinante (90.4%), seguido por **precio_unitario** (5.9%) y **descuento_pct** (3.7%). Esto refleja la regla de negocio: el volumen de compra es el principal indicador de perfil mayorista.

8.3 Datasets de Prueba Generados

Archivo	Filas	Periodo	Mayoristas	Minoristas	Casos borde
datos_prueba_50.csv	50	ene-feb 2026	32%	68%	15%
datos_prueba_200.csv	200	ene-abr 2026	34%	66%	15%
datos_prueba_500.csv	500	ene-jun 2026	39%	61%	15%

Cada dataset incluye:

- **fecha**: timestamp para analisis temporal (distribuido uniformemente en el periodo)
- **cantidad_kg**: 1-500 kg (segun perfil: mayorista >200, minorista <80, borde 80-250)
- **precio_unitario**: \$0.50 - \$60.00 (distribucion uniforme)
- **descuento_pct**: 0-30% (mayorista >10%, minorista <10%, borde 5-15%)
- **clase_real**: etiqueta verdadera para evaluacion del modelo

9. Conclusiones y Recomendaciones

9.1 Conclusiones

1. **Pipeline de datos robusto**: El proceso ETL con Apache Airflow y formato Parquet permite manejar grandes volumenes de datos con compresion eficiente y acceso selectivo por particiones.

2. **Evaluacion exhaustiva de modelos:** Se compararon 4 algoritmos de regresion y 4 de clasificacion, con cross-validation, analisis de residuos, curvas de aprendizaje y tuning de hiperparametros via GridSearchCV.
3. **Modelo final preciso:** El RandomForestClassifier alcanza ~92% de precision en datos de prueba, con una clara interpretabilidad gracias a las feature importances.
4. **Dashboard profesional:** La aplicacion Streamlit ofrece 4 modulos que cubren el ciclo completo de decision: prediccion individual, analisis batch, transparencia del modelo y simulacion de escenarios.
5. **Graficos interactivos:** La integracion con Plotly proporciona visualizaciones profesionales con tooltips, zoom, pan y colores semanticos que facilitan la interpretacion.
6. **Preparado para operacion:** El sistema incluye exportacion de resultados, datasets de prueba, documentacion exhaustiva y manejo de errores.

9.2 Recomendaciones para Evolucion

Prioridad	Recomendacion	Impacto
Alta	Agregar datos reales de transacciones historicas para mejorar la precision del modelo	Aumenta confiabilidad
Alta	Implementar autenticacion de usuarios en Streamlit	Seguridad
Media	Agregar SHAP/LIME para explicabilidad avanzada por prediccion	Confianza del usuario
Media	Conectar a base de datos en tiempo real (PostgreSQL, BigQuery)	Operacional
Media	Implementar alertas automaticas para transacciones en zona gris	Accion inmediata
Baja	Agregar exportacion de reportes PDF automaticos	Documentacion
Baja	Implementar A/B testing online del modelo vs reglas de negocio	Mejora continua
Baja	Desplegar en Streamlit Cloud o servidor corporativo	Accesibilidad

9.3 Lecciones Aprendidas

- La particion por fecha evita data leakage temporal en el train/test split
- Random Forest ofrece buen balance entre precision, interpretabilidad y velocidad de inferencia
- `max_depth=5` controla efectivamente el overfitting en datos sinteticos
- La feature importance revela que `cantidad_kg` domina la decision (90%)
- Los casos limite (zona gris) representan ~15% de las transacciones y requieren analisis manual
- El umbral de decision default (0.5) puede no ser optimo para todos los contextos de negocio

10. Anexos

Anexo A: Estructura del Proyecto

```

proyecto-streamlit-pkl/
├── app.py                                # Dashboard Streamlit (1100+ lineas, 4
modulos)
├── cuaderno.ipynb                       # Notebook completo de entrenamiento ML
(61 celdas)
├── modelo_clasificacion_retail.pkl      # Modelo RandomForest final (.pkl)
├── modelos.pptx                         # Presentacion de definicion de modelos
(15 slides)
├── requirements.txt                     # Dependencias Python
├── README.md                           # Documentacion del proyecto
├── informe-final.md                     # Este informe
├── docs/
│   └── streamlit_componentes.md        # Guia de componentes Streamlit y Plotly
├── datos_prueba_50.csv                  # Dataset de prueba: 50 transacciones
├── datos_prueba_200.csv                 # Dataset de prueba: 200 transacciones
└── datos_prueba_500.csv                 # Dataset de prueba: 500 transacciones

```

Anexo B: Como Ejecutar el Proyecto

```

# 1. Clonar el repositorio
git clone <url-del-repo>
cd proyecto-streamlit-pkl

# 2. Crear entorno virtual
python -m venv venv
.\venv\Scripts\Activate.ps1    # Windows PowerShell

# 3. Instalar dependencias
pip install -r requirements.txt

# 4. Ejecutar la aplicacion
streamlit run app.py

# 5. Abrir navegador en http://localhost:8501

```

Anexo C: Guia Rapida de Uso del Dashboard

Modulo	Que hacer	Que obtienes
Prediccion Individual	Ajustar 3 parametros en sidebar → "Clasificar"	Clase, confianza, gauge, waterfall, recomendaciones
Carga por Lote	Seleccionar dataset o subir CSV → automatico	KPIs, donut, histograma, serie temporal, tabla filtrable, exportar
Analisis del Modelo	Seleccionar dataset con <code>clase_real</code>	Feature importance, superficie decision, matriz confusion, ROC, metricas

Modulo	Que hacer	Que obtienes
Escenarios What-If	Elegir modo (sliders/curva/comparador)	Prediccion en tiempo real, curvas de sensibilidad, comparacion A/B

Anexo D: Referencias

- **Streamlit Documentation:** <https://docs.streamlit.io>
- **scikit-learn Documentation:** <https://scikit-learn.org>
- **Plotly Python Documentation:** <https://plotly.com/python>
- **Apache Airflow Documentation:** <https://airflow.apache.org>
- **Apache Parquet:** <https://parquet.apache.org>
- **Guia ETL en Airflow:** Semana 3 - Notion (Wilmer Palacios)

Documento generado el 27 de Mayo de 2026. Proyecto: Clasificador Retail Inteligente con Machine Learning y Streamlit.